

そのライブラリ、モデルと相性いいですか？

そのライブラリ、モデルと相性いいですか？

細かいけど効く 相性や設計など

DeNA

AI技術開発部AIイノベーショングループ

吉田 知貴

2026-09-29

自己紹介

吉田 知貴 (birder)



- 学生時代
 - 機械学習凸最適化の高速化 ([KDD2018](#), [KDD2019](#))
 - 2018年 DeNAサマーインターン
- 社会人
 - 2020年 DeNA新卒入社
 - エネルギー事業（組み合わせ最適化）
 - ライブ配信Pococha（[CS審査効率化](#)、[レコメンド](#)）
 - **新規AIプロダクト開発**（英語、マチアプ、受験など）

Qiita: [@birdwatcher](#)

X: [@birdwatcherYT](#)


目次

1. エージェントの基礎
2. 構造化出力のストリーミング
3. 同じモデルでも、経路で結果が違ふ
4. マルチエージェントの設計
5. エージェントを実装した時の工夫
6. 推論エンジンとモデル・GPUの相性

そのライブラリ、モデルと相性いいですか？

エージェントの基礎

エージェントとは？



- LLMを頭脳としたループが回る
- 事前に定義した**ツール**を**自律的に駆使**して応答する

エージェント実装の基本形 (LangChain)

```
# ① 応答形式の定義
class AgentOutput(BaseModel):
    reply: str = Field(description="応答文")
    suggestions: list[str] = Field(default_factory=list, description="選択肢")

# ② 自作ツール定義
@tool
def add(a: int, b: int) -> int:
    """2つの整数の和を返す""" # docstringがプロンプトに入る
    return a + b

# ③ モデル
llm = ChatOpenAI(
    model="gpt-5.6-sol",
    use_responses_api=True, # OpenAI の built-in ツール (例: web_search) を使うとき
)

# ④ エージェントが使えるツール集合定義
tools: list = [{"type": "web_search"}, add]
agent = create_agent(model=llm, tools=tools, response_format=AgentOutput)
```

エージェント開発で便利なトレースツール

ローカルでLangFuseを利用: エージェントがどんな動きをしているか知れる

The screenshot shows the LangFuse v3.150.0 OSS interface. The left sidebar contains navigation links: Home, Dashboards, Tracing, Sessions, Users, Prompt Management, Evaluation, LLM-as-a-Judge, Human Annotation, Datasets, Settings, and Support. The main area is divided into two panels. The left panel shows a list of traces with columns for Environment, Trace Name, Trace ID, User ID, Session ID, Metadata, Version, Release, Bookmarked, Comment Count, Comment Content, Tags, Level, Latency, Input Tokens, Output Tokens, Total Tokens, and Input Cost. The right panel shows a detailed view of a trace, including a search bar, a timeline, and a LangGraph execution flow. The flow starts with a 'start' node, followed by a 'model (3/3)' node, then a 'tools (2/2)' node, and finally an 'end' node. The 'tools' node is highlighted, showing its execution details.

プロンプト

1. ツール選択
by LLM (Cloud)
2. ツールA実行 (Local)
3. ツール選択
by LLM (Cloud)
4. ツールB実行 (Local)
5. 応答 by LLM (Cloud)

そのライブラリ、モデルと相性いいですか？

構造化出力のストリーミング

構造化出力のストリーミング

フィールド単位だけでなく、フィールド内でもストリーミングしたい

```
{}  
{"name": ""}  
{"name": "I"}  
{"name": "I am"}  
{"name": "I am a bird"}  
{"name": "I am a bird."}  
{"name": "I am a bird.", "age": 3}  
{"name": "I am a bird.", "age": 3, "like": ""}  
{"name": "I am a bird.", "age": 3, "like": "seed"}
```

- **ライブラリを使うとyieldで返ってくる粒度が荒くなる** → UX悪い
- 基本的にモデルからはJSONテキストの断片がstrで届く
 - 自分でパースするほうが細かく出力できる
 - → 括弧が閉じられていない不完全JSONをパースする便利な関数がLangChainにある (`parse_partial_json`)

構造化ストリーミングの粒度比較（単発LLM呼出）

粒度はプロバイダ × 方式 × ライブラリ依存（出力: 8フィールドJSON, 800～1100字）

モデル	LangChain json_schema	LangChain function_ calling	LangChain json_mode	LangChain JsonOutput Parser	ネイティブSDK partial_mode =True	ネイティブSDK +後処理でLCの parse_partial_json	ネイティブSDK パースなしstr (参考値)
Azure GPT-5.6 Sol	1	42	28	189	13	227	252
Azure GPT-4.1	1	37	29	167	13	185	210
Gemini 3.6 Flash	3	1	3	10	非対応	7	8
Gemini 2.5 Flash	2	1	2	8	非対応	5	7
Claude Sonnet 5	非対応	1	1	77	11	47	63
Claude Sonnet 4.6	非対応	1	1	110	13	55	77

- 数値は画面を更新できる回数
- **ネイティブの構造化出力の文字列を parse_partial_json にかけるのが一番良い**
- Geminiは少なく、Azure OpenAIが多い（生OpenAIも同じ）
- `JsonOutputParser` は複雑な構造だと崩壊するので非推奨



LangChainの create_agent の場合

Provider / モデル	astream_events('v2') × ToolStrategy(Profile)	astream_events('v2') × response_format=Profile	astream (stream_mode='updates')
Azure OpenAI GPT-5.6 Sol	chunk 208	chunk 230	update 3
Azure OpenAI GPT-4.1	chunk 222	chunk 175	update 3
Gemini 3.6 Flash	chunk 0	chunk 0	update 3
Gemini 2.5 Flash	chunk 0	chunk 0	update 3

- agent.astream_events でストリーミング開始すると event を受け取れる
 - on_chat_model_stream : chunk をバッファに足し parse_partial_json すれば良い
 - on_chain_end : structured_response から最終出力を確定
 - on_chat_model_end : web_search の実行検知 (built-in は on_tool に来ない)
 - on_tool_start / on_tool_end : カスタムツールの実行を知れる
- astream(updates) は 3つ (model → tools → model) レベルのイベントのみ
- Geminiで使うと逐次表示できない → **モデルと書き方の相性でこれだけの挙動差が生まれる**



そのライブラリ、モデルと相性いいですか？

同じモデルでも、経路で結果が違う

Geminiとライブラリの構造化出力

複雑なネストスキーマを100回生成した失敗率（temperature=0）

経路	3.1 Flash-Lite	2.5 Flash-Lite	主な失敗
Outlines	0%	2%	Pydantic 制約違反
google-genai	0%	9%	<code>parsed is None</code> （JSONが途中で尽きて不完全）
LangChain <code>json_schema</code>	0%	45%	<code>OutputParserException</code> （パーサ段で落ちる）
LangChain <code>function_calling</code>	100%	50%	Pydantic 制約違反（Geminiは <code>\$defs</code> 非対応 → ネスト制約が消える）

- Gemini 2.5 Flash-LiteでLangChainを使うと構造化出力の失敗確率が上がる
- GeminiとLangChainは相性が悪いと思っていたが、3系で改善されたか？

エージェントのタスク遂行能力を比較しよう

9件のセキュリティ警告を 6個の複合ルールで判定し、**7種類のツール**（ログ取得・脅威レベル判定・IPブロックなど）で全て対処するtoyタスク。

- 単純なタスクではない「**ログ取得 → 分析 → 対処**」を **9 件繰り返す** 必要あり
- 正しく完走するには **約 40 回のツール呼び出し** が必要

計測条件

- LangChain / Google ADK / Mastra / ネイティブSDK(auto / manual) を **12 モデル × 3 回** で比較
 - auto : SDKがツールループを内部完結 (google.genai の `automatic_function_calling`)
 - manual : 1 API 往復ずつ「generate → 実行 → 再送」ループを自力実装
- thinking / reasoning は全経路で未指定 = モデル既定 (3.6 Flash=MEDIUM / 3.5 Flash-Lite=MINIMAL / 3.1 Pro=HIGH / 2.5系=自動 / GPT-5.6=medium / GPT-4系=思考なし)
- temperature は対応モデルのみ 0

そのライブラリ、モデルと相性いいですか？

Model	ADK	LangChain	Mastra	ネイティブ auto	ネイティブ manual
Gemini 3.6 Flash	〇〇〇 / 47s / 41回	〇〇〇 / 41s / 41回	〇〇△ / 37s / 41回	〇〇〇 / 40s / 41回	〇△〇 / 39s / 41回
Gemini 3.5 Flash-Lite	△△× / 16s / 40回 HIGHを誤ブロック	×△△ / 11s / 41回 CRITICAL放置+虚偽報告	△×× / 11s / 41回 CRITICAL放置+誤ブロック	××△ / 11s / 41回 未実行を実施と報告	×△△ / 14s / 39回 未実行を実施と報告
Gemini 3.1 Pro (Preview)	〇〇〇 / 47s / 41回	△△〇 / 48s / 38回 エスカレ統合1回=過大報告	〇〇〇 / 35s / 41回	〇×〇 / 44s / 40回 未実施を実施と報告	〇〇〇 / 45s / 42回
Gemini 2.5 Pro	△△△ / 62s / 36回	〇△△ / 63s / 39回	△〇△ / 66s / 40回	×〇△ / 57s / 27回 ツール0回	△△× / 68s / 27回 ツール0回
Gemini 2.5 Flash	××× / 42s / 27回 MALFORMED FC	××× / 91s / 28回 MALFORMED FC	△△△ / 53s / 38回	△△△ / 79s / 46回 全件エスカレ=過剰	△△△ / 81s / 46回 全件エスカレ=過剰
Gemini 2.5 Flash-Lite	××△ / 172s / 37回 収集のみ→捏造	××× / 67s / 441回 捏造+1324回の暴走で打ち切り	××× / 9s / 0回 ツール0回・架空IP	××× / 18s / 42回 ブロック対象を誤り	××× / 41s / 42回 ブロック対象を誤り
GPT-5.6 Sol	〇〇〇 / 44s / 44回	〇〇〇 / 53s / 42回	〇〇〇 / 44s / 42回	SDK非対応	〇〇〇 / 61s / 43回
GPT-5.6 Terra	〇〇〇 / 39s / 41回	〇〇〇 / 32s / 42回	△〇〇 / 33s / 42回	SDK非対応	〇〇〇 / 31s / 41回
GPT-5.6 Luna	△×〇 / 26s / 43回 5.6系で唯一の捏造	〇〇〇 / 33s / 42回	△△△ / 29s / 44回	SDK非対応	〇〇△ / 30s / 42回
GPT-4.1	△△× / 41s / 45回 3runとも捏造	△△△ / 30s / 46回 存在しないアラートID	△×△ / 42s / 44回 3runとも捏造	SDK非対応	×〇△ / 26s / 41回 未実行を実施と報告
GPT-4.1 Mini	△△△ / 49s / 42回	△×× / 47s / 39回 3runとも虚偽報告	△△× / 43s / 39回 未実行を実施と報告	SDK非対応	△×△ / 37s / 43回 未実行を実施と報告
GPT-4o	△△〇 / 28s / 42回	×△△ / 43s / 41回 ブロック対象を誤り	×△× / 20s / 42回 ブロック対象を誤り	SDK非対応	×△△ / 25s / 42回 ブロック対象を誤り

3回の結果 / 平均実行時間 / 平均ツール呼出回数。〇=成功 / △=ルール違反や欠落あり / ×=失敗（捏造・エラー・空回答）。



結果からわかること

- Gemini 2.5 Flash系 → ネイティブSDKが最もまともにツールを呼べる
- 同じ2.5系でもFWで壊れ方が違う
 - ADK/LC × Flash: MALFORMED FC
 - LC × Flash-Lite: 暴走
 - Mastra × Flash-Lite: ツール0回
- 高性能モデルでは差が少ない: Gemini 3.6 / 3.1 Pro ・ GPT-5.6などほぼ〇

仕様アップデートを追おう

- Gemini
 - thinking: 2.5系= `thinking_budget` / 3系= `thinking_level`
 - デフォルト値： Gemini 3はHIGH → Gemini 3.5でMEDIUM
 - temperature: 3.5で非推奨・3.6以降は無効
- Open AI
 - reasoning: GPT-5.4はNone → GPT-5.6でmedium
- Mastra（ライブラリ側）
 - temperature: ライブラリ既定値=0 → プロバイダ既定値へ変更された

考えずにアップデートすると、デフォルト値が変わったり、効かなくなったりする。

そのライブラリ、モデルと相性いいですか？

マルチエージェントの設計

マルチエージェントにおける連携方法の比較

アラート **3 件**を、親エージェントが専門家に振り分けて対処するtoyタスク

- 想定ツール数 **約14回**、複雑な複合ルールなし
- **Coordinator**（親）：アラート一覧・ログ取得 → 専門家に委譲 → 最終報告
 - **network_analyst**（サブ）：攻撃元IPの脅威レベル判定・所有者調査
 - **incident_responder**（サブ）：IPブロック / 監視リスト追加 / エスカレ

	ADK	LangChain	Mastra
Agent as Tool 依頼文だけ渡す	AgentTool	@tool	@tool 同等
Subagent 制御・セッションを共有	sub_agents	Command(goto=)	機構が無い

Agent as Tool 3FW + Subagent 2FW × 12モデル × 3回 = **180 実行**



委譲形式と成功率

委譲形式別の ○率（12モデル × 3run = 各36実行）

委譲形式	実装	○率
Agent as Tool（依頼文だけ）	ADK AgentTool	97%
	LangChain @tool	97%
	Mastra @tool 同等	72%
Subagent（制御移譲）	ADK sub_agents	75%
	LangChain Command(goto=)	75%

- 同じライブラリ間では **Agent as Tool のほうが達成率が高かった**
- 失敗の違い
 - Agent as Tool: **エラーなく捏造** — サブ/親が虚偽の完了報告
 - Subagent: **制御が戻らず早期停止**。ログ取得だけで対処ゼロのまま終了

そのライブラリ、モデルと相性いいですか？

エージェントを実装した時の工夫

コンテキスト管理

- **スライディングウィンドウ**: 直近NメッセージのみDBから復元
- **再取得可能なツール出力は捨てる**: 取得系ツールは必要なときに呼べば良い
- **再現不能なツール出力は保存**: `web_search` など1回きりの出力は `tool_call` + `ToolMessage` ペアに再構成して履歴に注入
- **オンデマンド指示**: ツールから取得したデータを「どう使うか」の指示をツール結果に同梱。(システムプロンプトを圧迫しない工夫)
- **提示に必要な最小限だけ返す**: ツールで生成してDBに保存する場合、戻り値はエージェントが使う予定のもの（代表やサマリー）だけでよい → **レイテンシ改善に大きく効いた**

上記はあるプロダクト開発の際の設計で、常に保存しつつ古いツール出力を消していくパターンもある

ToolとSkillsやMCPとの違い

- Tool: 定義と引数スキーマが常にシステムプロンプトに積まれる
- MCP: サーバーに登録された**全ツールの定義・引数スキーマが常にシステムプロンプトに積まれる**。ツールが増えるほどコンテキストウィンドウを圧迫する
- Skills: **概要（name / description）だけ読まれ、詳細（実装・手順・補助ファイル）は使うときに初めてロードされる**。オンデマンド型

MCP/Tool を Skill で括ると圧迫を防げる: 初期プロンプトには Skill の概要だけが載り、必要になった時点で Skill 内の MCP/Tool 群がロードされる

Skills（オンデマンドプロンプト）を実装するには

方針

- エージェントに常に与えるのは**指示書をロードするだけのツール群**（引数なし）
- 指示書を読み込むツールが呼ばれると、それに紐づく**ツールとプロンプトが以降エージェントに与えられる**ようになる（寿命の設計は必要）

実装

- `load_skill_<name>`（引数なし）を**Skillの数だけ動的生成し、常時bind**。呼ばれると `skill.md` を返す
- **同一ターン内でcreate_agentを組み直す**: `create_agent` はツール固定 → `on_tool_end` で `load_skill_*` を検知したらstreamをbreak、ツール集合に足して**同じmessages列で再stream**
- **寿命**: 直近 **N 件**だけ残す。次リクエスト先頭でbindするので、一度読み込めば数ターン**再ロード不要**

効果: Skill固有のツール定義と指示が**必要なときしか載らない** → トークン削減

そのライブラリ、モデルと相性いいですか？

推論エンジンとモデル・GPUの相性

vLLM と SGLang、どちらが速い？

どちらも OpenAI 互換 API で LLM をセルフホストできる推論エンジン

- **vLLM: PagedAttention** で KV キャッシュを小分けにして持ち、メモリの無駄を省く定番のエンジン
- **SGLang: RadixAttention** でシステムプロンプトなど先頭が同じ部分（prefix）の計算結果を共有し、再計算を省く

実験設定

- モデル: Gemma 4 E4B / 12B
- GPU: L4 / A100

TTFT と TPOT の計測結果 (p50)

モデル	量子化	GPU	エンジン	TTFT 1並列	TTFT 8並列	TTFT 64並列	TPOT 1並列	TPOT 8並列	TPOT 64並列
E4B	BF16	L4	vLLM	59	132	428	39.1	40.7	53.9
			SGLang	114	180	474	39.9	41.7	53.4
E4B	BF16	A100	vLLM	35	68	248	10.2	10.8	13.5
			SGLang	92	196	433	11.0	11.6	13.8
12B	BF16	A100	vLLM	62	125	409	23.3	26.3	37.6
			SGLang	97	196	510	21.0	21.5	29.8
12B	FP8	A100	vLLM	58	120	432	16.1	17.4	27.1
			SGLang	110	237	565	13.2	14.0	21.4

- **TTFT** (Time To First Token) : 最初のトークンが返るまでの時間 (ms)
- **TPOT** (Time Per Output Token) : 1トークンあたりの生成時間 (ms/token)

どちらが速いかは一概に言えず、モデルと指標によって入れ替わる

結果からわかること

- TTFT はほぼ全水準で vLLM。1 並列では SGLang のほぼ半分
- 小さいモデル (E4B) は vLLM: TPOT は互角なので TTFT の差がそのまま効く
- 12B の decode は SGLang が 10～21% 速い: TTFT の不利は 15～18 トークン目で取り返す → 長い応答なら SGLang が先に終わる
- A100 の FP8 は重みだけ 8bit (Ampere は FP8 演算を持たない)
 - decode は 28～37% 速くなるが、prefill (TTFT) は速くならない
- エンジンの優劣はモデル・GPU・並列数で入れ替わる。既定値のまま比べると、エンジンではなく設定の差を測ってしまう

まとめ

- 構造化出力のストリーミングは **ネイティブSDKの文字列 + `parse_partial_json`** が細かく出せる
- ライブラリとモデルには相性がある（公式だけ使いたい気持ちに）
- マルチエージェントはAgent as Tool の方が達成率が高い（タスクに依ると思うが）
- 推論エンジンも、どちらが速いかはモデルや指標によって変わる
- アップデート時は仕様を追わないと予期せぬバグにつながる

おまけ: Geminiの価格は世代ごとに上がっている

グループ	モデル	入力（1M）	出力（1M）	世代比（対2.0基準）
Flash-Lite	2.0 Flash-Lite	\$0.075	\$0.30	基準
	2.5 Flash-Lite	\$0.10	\$0.40	約1.3倍
	3.1 Flash-Lite	\$0.25	\$1.50	入力 約3.3倍 / 出力 5倍
	3.5 Flash-Lite	\$0.30	\$2.50	入力 4倍 / 出力 8.3倍
Flash	2.0 Flash	\$0.10	\$0.40	基準
	2.5 Flash	\$0.30	\$2.50	入力 3倍 / 出力 6.25倍
	3 Flash (Preview)	\$0.50	\$3.00	入力 5倍 / 出力 7.5倍
	3.5 Flash	\$1.50	\$9.00	入力 15倍 / 出力 22.5倍
	3.6 Flash	\$1.50	\$7.50	入力 15倍 / 出力 18.75倍
Pro	2.5 Pro	\$1.25 / \$2.50*	\$10.00 / \$15.00*	基準
	3.1 Pro (Preview)	\$2.00 / \$4.00*	\$12.00 / \$18.00*	入力 1.6倍 / 出力 1.2倍

* 長いコンテキスト（20万トークン超）の場合の価格

おまけ: OpenAIの価格も上昇傾向か

グループ	モデル名	入力価格 (1M)	出力価格 (1M)	世代比 (各グループ基準対比)
Nano	GPT-4.1 Nano	\$0.10	\$0.40	基準
	GPT-5 Nano	\$0.05	\$0.40	入力 0.50倍 / 出力 1.00倍
	GPT-5.4 Nano	\$0.20	\$1.25	入力 2.00倍 / 出力 3.125倍
Mini	GPT-4o Mini	\$0.15	\$0.60	基準
	GPT-5 Mini	\$0.25	\$2.00	入力 約1.67倍 / 出力 約3.33倍
	GPT-4.1 Mini	\$0.40	\$1.60	入力 約2.67倍 / 出力 約2.67倍
	GPT-5.4 Mini	\$0.75	\$4.50	入力 5.00倍 / 出力 7.50倍
Standard	GPT-4o	\$2.50	\$10.00	基準
	GPT-4.1	\$2.00	\$8.00	入力 0.80倍 / 出力 0.80倍
	GPT-5	\$1.25	\$10.00	入力 0.50倍 / 出力 1.00倍
	GPT-5.2	\$1.75	\$14.00	入力 0.70倍 / 出力 1.40倍
	GPT-5.4	\$2.50	\$15.00	入力 1.00倍 / 出力 1.50倍