

そのライブラリ、モデルと相性いいですか？

# そのライブラリ、モデルと相性いいですか？

細かいけど効く 相性や設計など

**DeNA**

AI技術開発部AIイノベーショングループ

吉田 知貴

2026-09-29

# 自己紹介

## 吉田 知貴 (birder)



- 学生時代
  - 機械学習凸最適化の高速化 ([KDD2018](#), [KDD2019](#))
  - 2018年 DeNAサマーインターン
- 社会人
  - 2020年 DeNA新卒入社
  - エネルギー事業（組み合わせ最適化）
  - ライブ配信Pococha（[CS審査効率化](#)、[レコメンド](#)）
  - **新規AIプロダクト開発**（英語、マチアップ、受験、音声対話など）

Qiita: [@birdwatcher](#)

X: [@birdwatcherYT](#)


# 目次

1. エージェントの基礎
2. 構造化出力のストリーミング
3. モデル・ライブラリの比較と選定
4. マルチエージェントの連携方式
5. 推論エンジンの性能比較

そのライブラリ、モデルと相性いいですか？

# エージェントの基礎

# エージェントとは？



- LLMを頭脳としたループが回る
- 事前に定義した**ツール**を**自律的に駆使**して応答する

# エージェント実装の基本形 (LangChain)

```
# ① 応答形式の定義
class AgentOutput(BaseModel):
    reply: str = Field(description="応答文")
    suggestions: list[str] = Field(default_factory=list, description="選択肢")

# ② 自作ツール定義
@tool
def add(a: int, b: int) -> int:
    """2つの整数の和を返す""" # docstringがプロンプトに入る
    return a + b

# ③ モデル
llm = ChatOpenAI(
    model="gpt-5.6-sol",
    use_responses_api=True, # OpenAI の built-in ツール (例: web_search) を使うとき
)

# ④ エージェントが使えるツール集合定義
tools: list = [{"type": "web_search"}, add]
agent = create_agent(model=llm, tools=tools, response_format=AgentOutput)
```

# エージェント開発で便利なトレースツール

ローカルでLangFuseを利用: エージェントがどんな動きをしているか知れる

The screenshot shows the LangFuse v3.150.0 OSS interface. The left sidebar contains navigation links: Home, Dashboards, Tracing, Sessions, Users, Prompt Management, Evaluation, LLM-as-a-Judge, Human Annotation, and Datasets. The main area is divided into two panels. The left panel shows a list of traces with columns for Environment, Trace Name, Trace ID, User ID, Session ID, Metadata, Version, Release, Bookmarked, Comment Count, Comment Content, Tags, Level, Latency, Input Tokens, Output Tokens, and Total Tokens. The right panel shows a detailed view of a trace, including a tree structure of the execution flow and a diagram at the bottom showing the flow from 'start' to 'model (3/3)' to 'tools (2/2)' to 'end'.

プロンプト

1. ツール選択  
by LLM (Cloud)
2. ツールA実行 (Local)
3. ツール選択  
by LLM (Cloud)
4. ツールB実行 (Local)
5. 応答 by LLM (Cloud)

そのライブラリ、モデルと相性いいですか？

# 構造化出力のストリーミング

# 構造化出力のストリーミング

フィールド単位だけでなく、フィールド内でもストリーミングしたい

```
{}  
{ "name": "" }  
{ "name": "I" }  
{ "name": "I am" }  
{ "name": "I am a bird" }  
{ "name": "I am a bird." }  
{ "name": "I am a bird.", "age": 3 }  
{ "name": "I am a bird.", "age": 3, "like": "" }  
{ "name": "I am a bird.", "age": 3, "like": "seed" }
```

- **ライブラリを使うとyieldで返ってくる粒度が荒くなる** → UX悪い
- 基本的にモデルからはJSONテキストの断片がstrで届く
  - 自分でパースするほうが細かく出力できる
  - → 括弧が閉じられていない不完全JSONをパースする便利な関数がLangChainにある ( `parse_partial_json` )

# 構造化ストリーミングの粒度比較（単発LLM呼出）

粒度はプロバイダ × 方式 × ライブラリ依存（出力: 8フィールドJSON, 800～1100字）

| モデル               | LangChain<br>json_schema | LangChain<br>function_<br>calling | LangChain<br>json_mode | LangChain<br>JsonOutput<br>Parser | ネイティブSDK<br>partial_mode<br>=True | ネイティブSDK<br>+後処理でLCの<br>parse_partial_json | ネイティブSDK<br>パースなしstr<br>(参考値) |
|-------------------|--------------------------|-----------------------------------|------------------------|-----------------------------------|-----------------------------------|--------------------------------------------|-------------------------------|
| Azure GPT-5.6 Sol | 1                        | 42                                | 28                     | 189                               | 13                                | 227                                        | 252                           |
| Azure GPT-4.1     | 1                        | 37                                | 29                     | 167                               | 13                                | 185                                        | 210                           |
| Gemini 3.6 Flash  | 3                        | 1                                 | 3                      | 10                                | 非対応                               | 7                                          | 8                             |
| Gemini 2.5 Flash  | 2                        | 1                                 | 2                      | 8                                 | 非対応                               | 5                                          | 7                             |
| Claude Sonnet 5   | 非対応                      | 1                                 | 1                      | 77                                | 11                                | 47                                         | 63                            |
| Claude Sonnet 4.6 | 非対応                      | 1                                 | 1                      | 110                               | 13                                | 55                                         | 77                            |

- 数値は画面を更新できる回数
- **ネイティブの構造化出力の文字列を `parse_partial_json` にかけるのが一番良い**
- Geminiは少なく、Azure OpenAIが多い（生OpenAIも同じ）
- `JsonOutputParser` は複雑な構造だと崩壊するので非推奨



# LangChainの create\_agent の場合

| Provider / モデル           | astream_events('v2')<br>× ToolStrategy(Profile) | astream_events('v2')<br>× response_format=Profile | astream<br>(stream_mode='updates') |
|--------------------------|-------------------------------------------------|---------------------------------------------------|------------------------------------|
| Azure OpenAI GPT-5.6 Sol | chunk 208                                       | chunk 230                                         | update 3                           |
| Azure OpenAI GPT-4.1     | chunk 222                                       | chunk 175                                         | update 3                           |
| Gemini 3.6 Flash         | chunk 0                                         | chunk 0                                           | update 3                           |
| Gemini 2.5 Flash         | chunk 0                                         | chunk 0                                           | update 3                           |

- agent.astream\_events でストリーミング開始すると event を受け取れる
  - on\_chat\_model\_stream : chunk をバッファに足し parse\_partial\_json すれば良い
  - on\_chain\_end : structured\_response から最終出力を確定
  - on\_chat\_model\_end : web\_search の実行検知 (built-in は on\_tool に来ない)
  - on\_tool\_start / on\_tool\_end : カスタムツールの実行を知れる
- astream(updates) は 3つ (model → tools → model) レベルのイベントのみ
- Geminiで使うと逐次表示できない → **モデルと書き方の相性でこれだけの挙動差が生まれる**



そのライブラリ、モデルと相性いいですか？

# モデル・ライブラリの比較と選定

# Geminiとライブラリの構造化出力

複雑なネストスキーマを100回生成した失敗率（temperature=0）

| 経路                                      | 3.1 Flash-Lite | 2.5 Flash-Lite | 主な失敗                                                       |
|-----------------------------------------|----------------|----------------|------------------------------------------------------------|
| Outlines                                | 0%             | 2%             | Pydantic 制約違反                                              |
| google-genai                            | 0%             | 9%             | <code>parsed is None</code> （JSONが途中で尽きて不完全）               |
| LangChain <code>json_schema</code>      | 0%             | 45%            | <code>OutputParserException</code> （パーサ段で落ちる）              |
| LangChain <code>function_calling</code> | 100%           | 50%            | Pydantic 制約違反（Geminiは <code>\$defs</code> 非対応 → ネスト制約が消える） |

- Gemini 2.5 Flash-LiteでLangChainを使うと構造化出力の失敗確率が上がる
- GeminiとLangChainは相性が悪いと思っていたが、3系で改善されたか？



# エージェントのタスク遂行能力を比較しよう

9件のセキュリティ警告を 6個の複合ルールで判定し、**7種類のツール**（ログ取得・脅威レベル判定・IPブロックなど）で全て対処するtoyタスク。

- 単純なタスクではない「**ログ取得 → 分析 → 対処**」を **9 件繰り返す** 必要あり
- 正しく完走するには **約 40 回のツール呼び出し** が必要

## 計測条件

- LangChain / Google ADK / Mastra / ネイティブSDK を **10 モデル × 3 回** で比較
  - ネイティブSDK：1 API 往復ずつ「generate → 実行 → 再送」ループを自力実装
- thinking / reasoning は全経路で未指定 = モデル既定（3.6 Flash=MEDIUM / 3.5 Flash-Lite=MINIMAL / 3.1 Pro=HIGH / 2.5系=自動 / GPT-5.6=medium / GPT-4系=思考なし）
- temperature は対応モデルのみ 0

# モデル × ライブラリ別のタスク遂行結果

| Model                 | ADK                             | LangChain                            | Mastra                              | ネイティブSDK                     |
|-----------------------|---------------------------------|--------------------------------------|-------------------------------------|------------------------------|
| Gemini 3.6 Flash      | 〇〇〇 / 47s / 41回                 | 〇〇〇 / 41s / 41回                      | 〇〇△ / 37s / 41回                     | 〇△〇 / 39s / 41回              |
| Gemini 3.5 Flash-Lite | △△× / 16s / 40回<br>HIGHを誤ブロック   | ×△△ / 11s / 41回<br>CRITICAL放置+虚偽報告   | △×× / 11s / 41回<br>CRITICAL放置+誤ブロック | ×△△ / 14s / 39回<br>未実行を実施と報告 |
| Gemini 2.5 Pro        | △△△ / 62s / 36回                 | 〇△△ / 63s / 39回                      | △〇△ / 66s / 40回                     | △△× / 68s / 27回<br>ツール0回     |
| Gemini 2.5 Flash      | ××× / 42s / 27回<br>MALFORMED FC | ××× / 91s / 28回<br>MALFORMED FC      | △△△ / 53s / 38回                     | △△△ / 81s / 46回<br>全件エスカレ=過剰 |
| Gemini 2.5 Flash-Lite | ××△ / 172s / 37回<br>収集のみ→捏造     | ××× / 67s / 441回<br>捏造+1324回の暴走で打ち切り | ××× / 9s / 0回<br>ツール0回・架空IP         | ××× / 41s / 42回<br>ブロック対象を誤り |
| GPT-5.6 Sol           | 〇〇〇 / 44s / 44回                 | 〇〇〇 / 53s / 42回                      | 〇〇〇 / 44s / 42回                     | 〇〇〇 / 61s / 43回              |
| GPT-5.6 Terra         | 〇〇〇 / 39s / 41回                 | 〇〇〇 / 32s / 42回                      | △〇〇 / 33s / 42回                     | 〇〇〇 / 31s / 41回              |
| GPT-5.6 Luna          | △×〇 / 26s / 43回<br>5.6系で唯一の捏造   | 〇〇〇 / 33s / 42回                      | △△△ / 29s / 44回                     | 〇〇△ / 30s / 42回              |
| GPT-4.1               | △△× / 41s / 45回<br>3runとも捏造     | △△△ / 30s / 46回<br>存在しないアラートID       | △×△ / 42s / 44回<br>3runとも捏造         | ×〇△ / 26s / 41回<br>未実行を実施と報告 |
| GPT-4.1 Mini          | △△△ / 49s / 42回                 | △×× / 47s / 39回<br>3runとも虚偽報告        | △△× / 43s / 39回<br>未実行を実施と報告        | △×△ / 37s / 43回<br>未実行を実施と報告 |

### 各セルの見方

3回の結果 /  
平均実行時間 /  
平均ツール呼出回数

### 結果の記号

○：成功  
△：ルール違反や欠落  
×：失敗（エラー・捏造・空回答）



## 結果からわかること

- Gemini 2.5 Flash系 → ネイティブSDKが最もまともにツールを呼べる
- 同じ2.5系でもFWで壊れ方が違う
  - ADK/LC × Flash: MALFORMED FC
  - LC × Flash-Lite: 暴走
  - Mastra × Flash-Lite: ツール0回
- 高性能モデルでは差が少ない: Gemini 3.6 Flash ・ GPT-5.6などほぼ〇

# 仕様アップデートを追おう

- Gemini
  - thinking: 2.5系= `thinking_budget` / 3系= `thinking_level`
    - デフォルト値： Gemini 3はHIGH → Gemini 3.5でMEDIUM
  - temperature: 3.5で非推奨・3.6以降は無効
- Open AI
  - reasoning: GPT-5.4はNone → GPT-5.6でmedium
- Mastra（ライブラリ側）
  - temperature: ライブラリ既定値=0 → プロバイダ既定値へ変更された

**考えずにアップデートすると、デフォルト値が変わったり、効かなくなったりする。**

# Geminiの価格は世代ごとに上がっている

| グループ       | モデル名                               | 入力価格（1M）         | 出力価格（1M）           | 世代比（各グループ基準対比）     |
|------------|------------------------------------|------------------|--------------------|--------------------|
| Flash-Lite | 2.0 Flash-Lite                     | \$0.075          | \$0.30             | 基準                 |
|            | 2.5 Flash-Lite                     | \$0.10           | \$0.40             | 約1.3倍              |
|            | 3.1 Flash-Lite                     | \$0.25           | \$1.50             | 入力 約3.3倍 / 出力 5倍   |
|            | 3.5 Flash-Lite                     | \$0.30           | \$2.50             | 入力 4倍 / 出力 8.3倍    |
| Flash      | 2.0 Flash                          | \$0.10           | \$0.40             | 基準                 |
|            | 2.5 Flash                          | \$0.30           | \$2.50             | 入力 3倍 / 出力 6.25倍   |
|            | 3 Flash (Preview)                  | \$0.50           | \$3.00             | 入力 5倍 / 出力 7.5倍    |
|            | 3.5 Flash                          | \$1.50           | \$9.00             | 入力 15倍 / 出力 22.5倍  |
|            | 3.6 / 3.7 / 3.8 Flash <sup>†</sup> | \$1.50           | \$7.50             | 入力 15倍 / 出力 18.75倍 |
| Pro        | 2.5 Pro                            | \$1.25 / \$2.50* | \$10.00 / \$15.00* | 基準                 |
|            | 3.1 Pro (Preview)                  | \$2.00 / \$4.00* | \$12.00 / \$18.00* | 入力 1.6倍 / 出力 1.2倍  |

\* 長いコンテキスト（20万トークン超）の場合の価格

† 2026/12/31まではこの価格の半額。



# OpenAIの価格も上昇傾向か

| グループ     | モデル名         | 入力価格（1M） | 出力価格（1M） | 世代比（各グループ基準対比）        |
|----------|--------------|----------|----------|-----------------------|
| Nano     | GPT-4.1 Nano | \$0.10   | \$0.40   | 基準                    |
|          | GPT-5 Nano   | \$0.05   | \$0.40   | 入力 0.50倍 / 出力 1.00倍   |
|          | GPT-5.4 Nano | \$0.20   | \$1.25   | 入力 2.00倍 / 出力 3.125倍  |
| Mini     | GPT-4o Mini  | \$0.15   | \$0.60   | 基準                    |
|          | GPT-5 Mini   | \$0.25   | \$2.00   | 入力 約1.67倍 / 出力 約3.33倍 |
|          | GPT-4.1 Mini | \$0.40   | \$1.60   | 入力 約2.67倍 / 出力 約2.67倍 |
|          | GPT-5.4 Mini | \$0.75   | \$4.50   | 入力 5.00倍 / 出力 7.50倍   |
| Standard | GPT-4o       | \$2.50   | \$10.00  | 基準                    |
|          | GPT-4.1      | \$2.00   | \$8.00   | 入力 0.80倍 / 出力 0.80倍   |
|          | GPT-5        | \$1.25   | \$10.00  | 入力 0.50倍 / 出力 1.00倍   |
|          | GPT-5.2      | \$1.75   | \$14.00  | 入力 0.70倍 / 出力 1.40倍   |
|          | GPT-5.4      | \$2.50   | \$15.00  | 入力 1.00倍 / 出力 1.50倍   |

そのライブラリ、モデルと相性いいですか？

# マルチエージェントの連携方式

# マルチエージェントにおける連携方法の比較

アラート **3 件**を、親エージェントが専門家に振り分けて対処するtoyタスク

- 想定ツール数 **約14回**、複雑な複合ルールなし
- **Coordinator**（親）：アラート一覧・ログ取得 → 専門家に委譲 → 最終報告
  - **network\_analyst**（サブ）：攻撃元IPの脅威レベル判定・所有者調査
  - **incident\_responder**（サブ）：IPブロック / 監視リスト追加 / エスカレ

|                                 | ADK        | LangChain      | Mastra   |
|---------------------------------|------------|----------------|----------|
| <b>Agent as Tool</b><br>依頼文だけ渡す | AgentTool  | @tool          | @tool 同等 |
| <b>Subagent</b><br>制御・セッションを共有  | sub_agents | Command(goto=) | 機構が無い    |



# 委譲形式と成功率

委譲形式別の ○率（12モデル × 3run = 各36実行）

| 委譲形式                 | 実装                       | ○率  |
|----------------------|--------------------------|-----|
| Agent as Tool（依頼文だけ） | ADK AgentTool            | 97% |
|                      | LangChain @tool          | 97% |
|                      | Mastra @tool 同等          | 72% |
| Subagent（制御移譲）       | ADK sub_agents           | 75% |
|                      | LangChain Command(goto=) | 75% |

- 同じライブラリ間では **Agent as Tool のほうが達成率が高かった**
- 失敗の違い
  - Agent as Tool: **エラーなく捏造** — サブ/親が虚偽の完了報告
  - Subagent: **制御が戻らず早期停止**。ログ取得だけで対処ゼロのまま終了



そのライブラリ、モデルと相性いいですか？

# 推論エンジンの性能比較

# vLLM と SGLang、どちらが速い？

どちらも OpenAI 互換 API で LLM をセルフホストできる推論エンジン

- **vLLM: PagedAttention** で KV キャッシュを小分けにして持ち、メモリの無駄を省く定番のエンジン
- **SGLang: RadixAttention** でシステムプロンプトなど先頭が同じ部分（prefix）の計算結果を共有し、再計算を省く

## 実験設定

- モデル: Gemma 4 E4B / 12B
- GPU: L4 / A100

## TTFT と TPOT の計測結果 (p50)

| モデル | 量子化  | GPU  | エンジン   | TTFT<br>1並列 | TTFT<br>8並列 | TTFT<br>64並列 | TPOT<br>1並列 | TPOT<br>8並列 | TPOT<br>64並列 |
|-----|------|------|--------|-------------|-------------|--------------|-------------|-------------|--------------|
| E4B | BF16 | L4   | vLLM   | 59          | 132         | 428          | 39.1        | 40.7        | 53.9         |
|     |      |      | SGLang | 114         | 180         | 474          | 39.9        | 41.7        | 53.4         |
| E4B | BF16 | A100 | vLLM   | 35          | 68          | 248          | 10.2        | 10.8        | 13.5         |
|     |      |      | SGLang | 92          | 196         | 433          | 11.0        | 11.6        | 13.8         |
| 12B | BF16 | A100 | vLLM   | 62          | 125         | 409          | 23.3        | 26.3        | 37.6         |
|     |      |      | SGLang | 97          | 196         | 510          | 21.0        | 21.5        | 29.8         |
| 12B | FP8  | A100 | vLLM   | 58          | 120         | 432          | 16.1        | 17.4        | 27.1         |
|     |      |      | SGLang | 110         | 237         | 565          | 13.2        | 14.0        | 21.4         |

- **TTFT** (Time To First Token) : 最初のトークンが返るまでの時間 (ms)
- **TPOT** (Time Per Output Token) : 1トークンあたりの生成時間 (ms/token)

どちらが速いかは一概に言えず、モデルと指標によって入れ替わる

## まとめ

- 構造化出力のストリーミングは **ネイティブSDKの文字列** + `parse_partial_json` が細かく出せる
- ライブラリとモデルには相性がある（公式だけ使いたい気持ちに）
- マルチエージェントはAgent as Tool の方が達成率が高い（タスクに依ると思うが）
- 推論エンジンも、どちらが速いかはモデルや指標によって変わる
- アップデート時は仕様を追わないと予期せぬバグにつながる

そのライブラリ、モデルと相性いいですか？

## Appendix: Skillsをセルフ実装する

# ToolとSkillsやMCPとの違い

- **Tool:** 定義と引数スキーマが常にシステムプロンプトに積まれる
- **MCP:** サーバーに登録された**全ツールの定義・引数スキーマ**が常にシステムプロンプトに積まれる。ツールが増えるほどコンテキストウィンドウを圧迫する
- **Skills:** **概要（name / description）だけ読まれ**、詳細（実装・手順・補助ファイル）は**使うときに初めてロードされる**。オンデマンド型

**MCP/Tool を Skill で括ると圧迫を防げる:** 初期プロンプトには Skill の概要だけが載り、必要になった時点で Skill 内の MCP/Tool 群がロードされる

# Skills（オンデマンドプロンプト）を実装するには

## 方針

- エージェントに常に与えるのは**指示書をロードするだけのツール群**（引数なし）
- 指示書を読み込むツールが呼ばれると、それに紐づく**ツールとプロンプトが以降エージェントに与えられる**ようになる（寿命の設計は必要）

## 実装

- `load_skill_<name>`（引数なし）を**Skillの数だけ動的生成し、常時bind**。呼ばれると `skill.md` を返す
- **同一ターン内でcreate\_agentを組み直す**: `create_agent` はツール固定 → `on_tool_end` で `load_skill_*` を検知したらstreamをbreak、ツール集合に足して**同じmessages列で再stream**
- **寿命**: 直近 **N 件**だけ残す。次リクエスト先頭で bind するので、一度読み込めば数ターン**再ロード不要**

**効果**: Skill固有のツール定義と指示が**必要なときしか載らない** → トークン削減